



**1ACC0235 Procesamiento de Imágenes
Primer Avance del Trabajo Parcial**

Tema:

Modelo de detección de vehículos y objetos en calles peruanas

Profesor:

Javier Ulises Rosales Huamanchumo

Sección:

3238

Integrantes:

Ambrocio Tantalean, Ricardo Victor (U202315214)
León Quispe, Linda Libertad (U202322089)
Quispe Zavaleta, Jose Alberto (U20221C464)
Rivera Contreras, Pamela Ivonne (U202216662)

ÍNDICE

1. Introducción y Objetivos	3
2. Metodología CRISP-DM	3
3. Análisis Exploratorio de Datos (EDA)	5
4. Anexos	18

1. Introducción y Objetivos

Hoy en día el área de la autoconducción ha tenido un auge muy grande. Diversas empresas han creado sus propios modelos de detección de objetos en carreteras, el cual es el primer paso para lograr que un auto conduzca por su cuenta sin necesidad de un conductor humano.

Sin embargo, estos modelos están entrenados en entornos de conducción perfectos, o casi perfectos, como las carreteras de Alemania o Estados Unidos. Esto hace que al exponer al vehículo autónomo a calles con tráfico caótico como el nuestro falle estrepitosamente. El modelo no brinda un reconocimiento acertado ya que no reconoce los objetos que pasan frente a él mientras que para nosotros son comunes.

Por lo tanto, creemos que es necesario contar con un modelo de detección vial que pueda entender y desenvolverse correctamente en distintos entornos. Tanto en entornos con alta educación cívica como aquellos en los cuales aún la educación mencionada y el orden vehicular están en condiciones precarias.

El objetivo principal del proyecto es crear un modelo de detección vial que funcione correctamente en el tráfico peruano. Este modelo deberá de ser capaz de detectar los diversos objetos que día a día se presentan en las calles de nuestro país y que son casi inexistentes en otros países de primer mundo como mototaxis, desmonte, combis, etc.

2. Metodología CRISP-DM

Business Understanding

El problema que atiende este proyecto es la ausencia de modelos de detección vial entrenados para el contexto peruano. Los sistemas existentes de conducción autónoma han sido desarrollados en entornos con tráfico normado, lo que los hace incapaces de reconocer objetos viales propios del Perú como mototaxis, combis, carretillas o desmonte en vía pública.

La métrica objetivo principal es el $mAP@0.5$ (mean Average Precision con umbral IoU de 0.5), estándar en tareas de detección de objetos. Se establece como criterio de éxito que el modelo alcance un $mAP@0.5 \geq 0.65$ en el conjunto de validación, superando como línea base un detector genérico preentrenado en COCO sin fine-tuning aplicado al mismo dataset. Como métricas complementarias se considerarán un recall ≥ 0.60 para las clases críticas (mototaxi, peatón, vehículo) y un tiempo de inferencia menor a 50 ms por frame.

Data Understanding

Para el análisis exploratorio se utilizó el dataset robusto-1_extended de Artificio Org, disponible en Hugging Face. Este cuenta con 203 videos de 5 segundos grabados a 10

fps en primera persona desde un vehículo en movimiento, en tres ciudades del Perú: Lima, Cusco y Cajamarca. Todos los frames presentan resolución uniforme de 1920×1080 píxeles con 3 canales RGB.

Dado que el dataset está compuesto por videos, se extrajo un frame representativo por video, correspondiente al segundo 2.5 de cada grabación, evitando así frames negros de transición al inicio o al final. Esto resultó en 203 frames sobre los cuales se realizó el análisis.

Los principales hallazgos del EDA fueron los siguientes:

- **Distribución de Iluminación:** El histograma promedio en escala de grises muestra una distribución en campana ancha centrada entre las intensidades 80 y 110, reflejo de la combinación de asfalto, edificaciones y vegetación presente en escenas viales urbanas. Se detectó además un pico pronunciado cercano a la intensidad 250, indicativo de sobreexposición frecuente asociada a grabaciones diurnas.
- **Métricas de Brillo y Contraste:** El análisis de brillo por frame arrojó una media de 118.73/255, con la mayoría de frames concentrados entre 110 y 150, confirmando el predominio de condiciones diurnas. La desviación estándar del brillo entre frames fue de 21.48, valor moderado que indica variabilidad sin casos extremos. El frame más oscuro registró un brillo de 39/255 y el más brillante de 155.8/255. Respecto al contraste, la media fue de 57.93/255, valor favorable para la detección de objetos ya que implica suficiente diferencia de intensidad entre los elementos de interés y su entorno.
- **Diagnóstico de Sobreexposición:** Estableciendo un umbral en píxeles mayor igual a 245, se determinó que en promedio el 1.64% de los píxeles del dataset están quemados. Se identificaron 20 frames con más del 5% de pérdida de información y 9 con más del 10%, destacando el frame Robusto 1_16.mp4 como el caso más crítico con un 20.89% de píxeles quemados.
- **Desbalance Crítico de Iluminación:** Se identificó una severa asimetría en las condiciones temporales del dataset, registrándose un 88.7% de frames diurnos reales (180 imágenes) frente a un escaso 11.3% de frames nocturnos u oscuros (23 imágenes). Este marcado desbalance lumínico representa un riesgo directo de sesgo para el entrenamiento del modelo, ya que la escasez de muestras nocturnas impediría que la red neuronal aprenda a generalizar correctamente

en escenarios de baja visibilidad, provocando una inminente caída en las métricas de rendimiento global.

Data Preparation

Como respuesta a las limitaciones de calidad y el desbalance identificados en el EDA, el procesamiento de los datos se estructuró en dos decisiones principales:

- Filtro por Desbalance Lumínico (Exclusión Nocturna): Debido a que el dataset presentaba un sesgo crítico hacia las grabaciones diurnas (180 frames, 88.7%) frente a una presencia insuficiente de frames nocturnos/oscuros (23 frames, 11.3%), se decidió eliminar por completo la data nocturna real. Esta exclusión evitó contaminar el entrenamiento con muestras asimétricas que habrían provocado la caída de las métricas del modelo. Tras el filtrado, el dataset diurno se estabilizó con un brillo promedio de 123.99/255 y una desviación estándar optimizada de 16.08.
- Transformación Lineal: Utilizando parámetros de $a=0.75$ y $b=20$, logró reducir los píxeles quemados del peor caso al 0.00%, pero degradó el contraste global (cayendo de 73.98 a 55.39) al apagar la imagen de forma uniforme.
- CLAHE (Contrast Limited Adaptive Histogram Equalization): Aplicado de forma adaptativa con $\text{clipLimit}=2.0$ y $\text{tileGridSize}=(8,8)$ en el espacio HSV. CLAHE demostró ser la solución óptima: a nivel global redujo el promedio de píxeles quemados de 1.64% a solo 0.34% y elevó el contraste neto del dataset en +1.07 (std).

3. Análisis Exploratorio de Datos (EDA)

Para cumplir con el objetivo mencionado, primero debemos saber que datos vamos a utilizar para entrenar el modelo en cuestión. El conjunto de datos deberá de contar con una buena cantidad de videos o imágenes de los objetos mencionados, una buena calidad de resolución y una distribución uniforme de imágenes diurnas y nocturnas.

Hemos escogido el dataset [robusto_1_extended](#) de Artificio Org disponible en Hugging Face. Este cuenta con más de 200 videos de 5 segundos y 10 frames por segundo cada uno, conteniendo situaciones de manejo en primer plano en tres distintas ciudades del Perú como Cajamarca, Cusco y Lima.

Esto nos permite expandir nuestro panorama al no solo centrarnos en objetos de una ciudad tan urbanizada como la capital, sino también adaptarnos a los distintos paisajes del país.

Una vez definido el dataset a utilizar, podemos empezar con el *Análisis Exploratorio de Datos* el cual será listado a continuación:

Tamaño de las imágenes

Dado que el dataset está conformado por videos, para poder saber el tamaño de las imágenes tenemos que extraer por lo menos un frame de cada video. Es recomendable extraer el frame del medio (alrededor de 2 segundos y medio) para poder evitar inconvenientes como pantallas negras al inicio o final de cada video.


El total de videos que pudimos descargar es de 203, por lo tanto tendremos 203 frames en total.

Los resultados obtenidos nos dicen que todas las imágenes del dataset tienen el mismo alto y ancho (1920x1080 píxeles). Asimismo, cuentan con los mismos 3 canales de color RGB.


```
=== Tamaño de las imágenes ===  
Total de frames : 203  
Alto  - min: 1080px | max: 1080px | moda: 1080px  
Ancho - min: 1920px | max: 1920px | moda: 1920px  
Canales: [3] (3 = RGB/BGR)  
  
Todas las imágenes tienen el mismo tamaño: 1920x1080 px
```

Escala de Grises

Ahora, para poder resaltar la estructura, el contraste y la iluminación, eliminando distracciones de color para destacar texturas y formas vamos a convertir ciertas imágenes a escala de grises.



Para poder obtener un mejor análisis de lo que tenemos, creemos importante generar un histograma promedio de esta misma escala de grises.




Los resultados que obtenemos de la gráfica nos dicen que la distribución tiene forma de campana ancha y achatada centrada alrededor de 80–110 (tonos medios-oscuros), lo que refleja la combinación de asfalto, edificios y vegetación que están presentes en muchos escenarios de calles y carreteras del país mientras que el pico muy pronunciado cerca de la intensidad 250 puede sugerir una sobre exposición frecuente en el dataset.

Por otro lado, las oscilaciones (el aspecto "rugoso" que tienen) son normales al promediar histogramas de escenas muy distintas entre sí.


Histogramas RGB

Una vez analizadas las imágenes en escala de grises, creemos necesario también hacer un análisis de las imágenes en escala de colores RGB.




La presente figura muestra como un frame de un video de noche, y en consecuencia el histograma de intensidades tiene un pico muy alto en valores cercanos a cero. Esto hace sentido, ya que al ser un video nocturno, elementos con intensidades más bajas serán más frecuentes.



Por otro lado, en la siguiente figura se observa lo contrario. Al ser videos diurnos, la gráfica muestra una mayor concentración de elementos con intensidades cercanas a 250.




Asimismo, también existen videos con distribución más bimodal, lo cual indica una buena variedad tonal y los convierte en los videos más "saludables" e ideales dentro de nuestro dataset los cuales son los siguientes:



Histograma Promedio (RGB)

El histograma RGB muestra un grueso entre las intensidades 50 y 80 aproximadamente, lo que significa que nuestro dataset está compuesto en su mayoría por videos de iluminación media.

Sin embargo, también llama la atención el pico muy alto en las intensidades finales, cerca de 250. Esto confirma que hay sobreexposición y saturación. En otras palabras, tenemos una gran mayoría de videos que son grabados de día.



Distribución de Brillo y Contraste Promedio


La media obtenida es de 118.7/255 lo cual indica que el dataset en promedio está bien iluminado.

```
=== Estadísticas de brillo del dataset ===  
Brillo promedio (mean de grises) : 118.73 / 255  
Desviación estándar del brillo   : 21.48  
Contraste promedio (std de grises): 57.93  
Frame más oscuro   : Robusto 1_183.mp4 (brillo=39.1)  
Frame más brillante: Robusto 1_18.mp4 (brillo=155.8)
```


Además, nuestra gráfica muestra que la distribución tiene sesgo hacia la derecha, con la mayoría de frames concentrados entre 110 y 150. Esto confirma que la mayoría de grabaciones son diurnas y son mucho mayores comparadas a aquellas grabadas en la noche.

La desviación estándar del brillo entre frames es 21.48, moderada, lo que significa que los frames no son extremadamente dispares en luminosidad general.

Con respecto al frame más brillante y al más oscuro hay que notar que este último tiene apenas 39/255, mientras que el más brillante (155.8) indica que no hay frames extremadamente sobreexpuestos en brillo global.



Con respecto al contraste, la media es de 57.9 / 255. Lo cual nos dice que existe un contraste relativamente bueno a lo largo del dataset. No hay frames con contraste muy bajo (cercano a 0, que sería una imagen completamente uniforme o gris) ni tampoco extremos artificiales.




Además, un contraste medio de 57.9 es excelente para detección de objetos: significa que los vehículos, peatones y señales tienen suficiente diferencia de intensidad respecto a su entorno para que un modelo los distinga.


Análisis de Datos Nocturnos Reales y Justificación de Exclusión

A pesar de que las métricas globales sugieren un dataset con iluminación promedio saludable, un análisis desagregado de la frecuencia lumínica reveló una bimodalidad crítica: el 88.7% (180 frames) del conjunto corresponde a condiciones diurnas óptimas, mientras que apenas un 11.3% (23 frames) captura entornos de baja visibilidad o nocturnos reales.

Proporción de Frames Diurnos vs. Nocturnos/Oscuros Reales



Al colocar los histogramas de ambos subconjuntos frente a frente, se observa una disparidad matemática extrema. Mientras que los frames diurnos extienden su campana a lo largo de los tonos medios, los 23 frames oscuros comprimen casi toda la masa de sus píxeles contra el cero absoluto del eje de intensidades.



Desde la perspectiva del aprendizaje estadístico, incluir una fracción tan insignificante y morfológicamente diferente de datos nocturnos induce un sesgo de clase mayoritario destructivo. Durante el entrenamiento, el optimizador del modelo tenderá a ignorar las características de los objetos en la oscuridad para concentrarse en reducir el error del 88.7% diurno, provocando que las métricas globales caigan drásticamente debido a un alto índice de falsos negativos en escenarios de baja luz.

Por tales motivos, se justificó la decisión de excluir formalmente estos 23 frames del conjunto de entrenamiento original. Esta depuración purifica el core del dataset, permitiendo consolidar un modelo base robusto enfocado al 100% en el entorno diurno homogéneo de las calles peruanas.


Análisis del Dataset Filtrado (Solo Diurno)

Una vez ejecutada la exclusión de los 23 frames anómalos, se procedió a recalcular los histogramas y las métricas estadísticas sobre el nuevo conjunto depurado de 180 frames diurnos. Los cambios numéricos confirman la purificación y estabilización del núcleo de entrenamiento:

- **Incremento y Estabilización del Brillo:** El brillo promedio del dataset experimentó un ascenso, pasando de 118.73 a 123.99 / 255. Este desplazamiento matemático refleja un conjunto más homogéneo y fiel a las condiciones de iluminación natural diurna.
- **Reducción de la Dispersión (Varianza):** La desviación estándar del brillo global cayó drásticamente de 21.48 a 16.08. Esta reducción del 25.1% en la

dispersión es un indicador crítico de calidad; significa que los saltos bruscos de iluminación extrema entre un video y otro se han mitigado, compactando la distribución del dataset.

- **Conservación del Contraste:** El contraste promedio se mantuvo prácticamente intacto, moviéndose sutilmente de 57.93 a 57.19 / 255. Esto demuestra que retirar los frames oscuros no le restó riqueza ni dinamismo a las imágenes diurnas; los vehículos, baches y peatones siguen conservando la misma excelente separabilidad frente a su entorno urbano.
- **Control de Bordes Críticos:** El nuevo frame más oscuro (Robusto 1_176.mp4) ahora marca un brillo base de 90.7 / 255 (en contraste con el valor extremo anterior de 39.1). Esto sitúa el piso lumínico del dataset exactamente en el umbral seguro de la luz de día. El techo máximo se mantiene inalterado en 155.8 (Robusto 1_18.mp4), reafirmando la ausencia de sobreexposiciones globales destructivas.



Análisis de Color en Espacio HSV

Para robustecer la posterior clasificación y detección de objetos, se desacopló la información cromática de la intensidad lumínica migrando al espacio de color HSV (Hue, Saturation, Value). Los resultados promedios sobre el dataset diurno filtrado revelaron métricas clave:

- **Tono (Hue: 71.56):** La distribución confirma una fuerte presencia de tonos amarillos y verdes, consistentes con la vegetación de las carreteras interprovinciales (Cusco y Cajamarca) y la infraestructura urbana. La alta desviación estándar (42.52) ratifica una deseable variedad cromática para evitar sesgos en el modelo.

- Saturación (Saturation: 51.12): Refleja que las imágenes poseen colores predominantemente moderados y realistas, típicos de capturas en movimiento a través de parabrisas.
- Valor (Value: 137.55): Al representar el brillo intrínseco, una media de 137.55 confirma de manera cuantitativa que el dataset está firmemente posicionado en el espectro diurno, sirviendo como una base de alta visibilidad

```

=== Estadísticas de Canales HSV (Diurno Filtrado) ===
Tono (Hue) promedio      : 71.56
Saturación promedio      : 51.12
Valor (Brillo) promedio  : 137.55
---
Desv. Est. Tono (Hue)    : 42.52
Desv. Est. Saturación    : 38.74
Desv. Est. Valor (Brillo): 61.27

```

Diagnóstico de Sobreexpocisión


A pesar de la estabilidad del conjunto diurno, se ejecutó un diagnóstico de calidad para cuantificar imperfecciones lumínicas locales provocadas por la luz solar directa del mediodía o reflejos metálicos, estableciendo un umbral de sobreexposición estricto en valores mayores iguales a 245. El análisis determinó que, en promedio, el 1.64% de los píxeles del dataset se encuentran críticamente quemados. Sin embargo, se identificaron 20 frames con más del 5% de pérdida de información y 9 que superan el 10%. El caso crítico del dataset corresponde al video Robusto 1_16.mp4, registrando un 20.89% de píxeles quemados, concentrados en el cielo y superficies altamente reflectantes, lo que destruye el contraste local necesario para delimitar la silueta de los vehículos lejanos.

```

=== Diagnóstico de Sobreexposición (Dataset Diurno, 180 frames) ===
Umbral de sobreexposición : píxeles >= 245
% promedio de píxeles quemados : 1.64%
% máximo de píxeles quemados : 20.89%
Frames con > 5% de píxeles quemados: 20
Frames con > 10% de píxeles quemados: 9

Frame más sobreexpuesto: Robusto 1_16.mp4
→ 20.89% de sus píxeles están quemados

```



Evaluación de técnicas de procesamiento

Para mitigar la sobreexposición y potenciar la separabilidad de los objetos, se contrastaron dos aproximaciones algorítmicas utilizando el peor escenario (Robusto 1_16.mp4) como caso de estudio:



- Transformación Lineal: Aplicando parámetros de compresión ($a = 0.75$, $b = 20$), esta técnica de punto logró reducir el porcentaje de píxeles quemados del 20.89% al 0.00%. No obstante, el análisis revela que este método es destructivo para el contexto del proyecto: al comprimir el rango global de manera uniforme, redujo el brillo promedio a 130.55 y castigó el contraste global (cae de 73.98 a 55.39). Al "apagar" la imagen de forma pareja, se atenúan los detalles en las zonas de sombra, lo que perjudicaría la detección en calles con oclusión edilicia.

```

== Transformación Lineal (a=0.75, b=20) - Caso de estudio ==
% píxeles quemados ANTES : 20.89%
% píxeles quemados DESPUÉS: 0.00%
Brillo promedio ANTES : 148.02
Brillo promedio DESPUÉS: 130.55
Contraste (std) ANTES : 73.98
Contraste (std) DESPUÉS: 55.39



```

Técnica 1 — Transformación Lineal: $s = a \cdot r + b$



- CLAHE (Contrast Limited Adaptive Histogram Equalization): Al operar de forma local mediante bloques adaptativos ($\text{clipLimit}=2.0$, $\text{tileGrid}=(8,8)$) sobre el canal de luminancia V, CLAHE demostró ser una solución notablemente superior. En el caso de estudio, redujo los píxeles quemados a un aceptable 6.50%, pero incrementó sutilmente tanto el brillo promedio (148.68) como el contraste (74.66).

Técnica 2 — CLAHE: Ecuilización Adaptativa con Límite de Contraste



Impacto global de CLAHE

A nivel macro, el impacto global de CLAHE sobre los 180 frames valida su selección para el pipeline final:

- Redujo el porcentaje promedio de píxeles quemados en todo el dataset de 1.64% a apenas un 0.34%
- Elevó el contraste promedio de 57.19 a 58.26, logrando una mejora neta de +1.07 (std).
-

3. Product Backlog

ID	Épica	Historia de Usuario / Tarea	Prioridad	Estimación	Responsable
PB-01	Preparación de Datos	Extracción de frames: Extraer 1 frame central (segundo 2.5) de los 203 videos para armar el dataset estático.	Alta	3 pts	León Quispe, Linda Libertad

PB-02	Preparación de Datos	Validación de formato: Verificar y estandarizar la resolución de las imágenes (1920x1080 px) y distribución de canales.	Alta	2 pts	Rivera Contreras, Pamela Ivonne
PB-03	Análisis Exploratorio	Análisis de iluminación: Convertir imágenes a escala de grises y analizar histogramas para identificar problemas de sobreexposición diurna.	Media	3 pts	Rivera Contreras, Pamela Ivonne
PB-04	Preprocesamiento	Corrección de Exposición: Implementar Transformación Lineal en el dominio espacial para corregir la sobreexposición global.	Alta	5 pts	León Quispe, Linda Libertad
PB-05	Preprocesamiento	Mejora de Contraste: Aplicar el filtro CLAHE para optimizar el contraste local de forma adaptativa en el dataset.	Alta	5 pts	León Quispe, Linda Libertad

PB-06	Detección de Vehículos	Etiquetado (Anotación): Dibujar bounding boxes (etiquetas) de los vehículos en las imágenes para el entrenamiento.	Crítica	8 pts	Ambrocio Tantalean, Ricardo Victor
PB-07	Detección de Vehículos	Entrenamiento del Modelo: Configurar y entrenar un modelo de detección (ej. YOLO o Faster R-CNN) con el dataset diurno optimizado.	Crítica	13 pts	Quispe Zavaleta, Jose Alberto
PB-08	Detección de Vehículos	Evaluación de Rendimiento: Validar las métricas de precisión (mAP) del modelo y detectar posibles falsos positivos por problemas de luz.	Alta	5 pts	Quispe Zavaleta, Jose Alberto
PB-9	Documentación	Conclusiones y Recomendaciones: Redactar el reporte final detallando el impacto de la Transformación Lineal y CLAHE en el desempeño.	Media	3 pts	Ambrocio Tantalean, Ricardo Victor

4. Anexos

- Dataset Artificio/Robusto_Extended:
https://huggingface.co/datasets/Artificio/robusto-1_extended
- Notebook EDA:

<https://colab.research.google.com/drive/1N3XlRJFtql5bWIk5XBhyvQrH04WZoCPv#scrollTo=7f0447d1>

- Enlace al repositorio de código:
<https://github.com/pollitoconpapass/carritos-peruanitos-detector>
- Enlace al video demostrativo de 3 a 5 minutos:
<https://drive.google.com/drive/folders/1kuoeDodeDZL383ujF9ErWP1R8RiL9P1H?usp=sharing>